Predicción de la readmisión hospitalaria a 30 días en pacientes diabéticos mediante aprendizaje de máquina

Avance 1: descripción del problema y estado del arte

Jefferson Stiven Lizarazo Arias y Juan Ricardo Vélez Ciro

***Resumen*—Este avance describe el problema de predecir, al momento del alta, si un paciente diabético será readmitido en menos de 30 días, a partir del conjunto de datos *Diabetes 130-US Hospitals* (1999–2008). Se presenta el análisis exploratorio de las 101 766 hospitalizaciones originales, la estrategia de depuración, tratamiento de datos faltantes y codificación, que deja 69 987 pacientes independientes y 130 variables codificadas, y se justifica el planteamiento como un problema de clasificación supervisada binaria con clases desbalanceadas (8,98 % de positivos). Finalmente, se revisan cuatro artículos de revista que usan esta misma base de datos, cuyos desempeños (AUC entre 0,63 y 0,69) sirven como referencia para el resto del proyecto.**

***Index Terms*—Readmisión hospitalaria, diabetes mellitus, clasificación desbalanceada, aprendizaje supervisado, análisis exploratorio.**

I. Descripción del problema

I-A. Contexto y utilidad de una solución basada en ML

La readmisión hospitalaria temprana, es decir, el reingreso de un paciente en los 30 días siguientes a su alta, es un indicador de la calidad de la atención y una fuente importante de costos para los sistemas de salud. En el programa Medicare de EE. UU., Jencks *et al.* estimaron que cerca del 19,6 % de los pacientes dados de alta fue rehospitalizado en ese plazo, con un costo atribuido a las rehospitalizaciones no planificadas de 17,4 mil millones de dólares en 2004 [1]. En los pacientes con diabetes mellitus, además, el manejo de la hiperglucemia durante la hospitalización incide en la morbilidad y la mortalidad [2], lo que hace relevante identificar qué características de la hospitalización se asocian con un reingreso temprano.

Si al momento del alta se pudiera estimar qué pacientes tienen mayor riesgo de volver en menos de 30 días, el hospital podría focalizar intervenciones costosas (educación al paciente, ajuste de la medicación, seguimiento telefónico o visita domiciliaria) en quienes más las necesitan. El riesgo depende de numerosas variables heterogéneas (demográficas, administrativas, diagnósticas, de laboratorio y de medicación) cuyas interacciones no son evidentes ni fáciles de capturar con reglas manuales. Un modelo de aprendizaje de máquina (ML) entrenado con registros históricos puede aprender esos patrones y producir una puntuación de riesgo con la información disponible al alta, como herramienta de apoyo a la decisión clínica y no como sustituto del criterio médico.

Modelos y Simulación de Sistemas II, Ingeniería de Sistemas, Universidad de Antioquia, Medellín, Colombia.

Cuadro I
Variables del conjunto de datos agrupadas por tipo

Grupo	N.º	Variables y significado
Identificadores	2	`encounter_id` (hospitalización), `patient_nbr` (paciente)
Demográficas	4	Raza, género, edad (10 rangos de 10 años), peso (rangos)
Administrativas	5	Tipo de admisión, destino al alta, fuente de admisión, pagador, especialidad del médico tratante
Hospitalización	4	Días de estancia (1–14); n.º de pruebas de laboratorio, de procedimientos y de medicamentos
Historial	3	Visitas ambulatorias, a urgencias y hospitalizaciones en el año previo
Diagnósticos	4	Diagnóstico primario y dos secundarios (ICD-9); n.º de diagnósticos
Laboratorio	2	Glucosa sérica máxima y HbA1c (categorías; `None` = no medida)
Medicación	25	23 fármacos para diabetes (`No`, `Steady`, `Up`, `Down`); cambio de medicación; uso de medicación para diabetes
Objetivo	1	`readmitted`: `<30`, `>30`, `NO`

I-B. Composición de la base de datos

Origen. Se usa el conjunto *Diabetes 130-US Hospitals for Years 1999–2008* [3], construido por Strack *et al.* [2] a partir de la base Health Facts (Cerner Corporation) y publicado en el repositorio UCI. Se trabaja con la copia disponible en Kaggle [4], que tiene los mismos 101 766 registros. Incluye hospitalizaciones de pacientes con diagnóstico de diabetes, de entre 1 y 14 días de estancia, en las que se realizaron pruebas de laboratorio y se administraron medicamentos.

Tamaño y variables. El archivo `diabetic_data.csv` contiene 101 766 registros (hospitalizaciones) y 50 columnas: 2 identificadores, 47 variables predictoras y la variable objetivo `readmitted`, con tres valores: `NO` (53,9 %), `>30` (34,9 %) y `<30` (11,2 %). Un segundo archivo, `IDS_mapping.csv`, traduce los códigos de tipo de admisión (8 códigos), destino al alta (30) y fuente de admisión (25); contiene tres tablas apiladas que se separan antes de usarse. La Tabla I resume las variables por grupo y su significado.

Unidad de análisis y depuración. Cada fila es una hospitalización, no un paciente: hay 71 518 pacientes únicos y el 23,5 % tiene más de una hospitalización (máximo 40). Las hospitalizaciones de un mismo paciente no son independientes; si quedaran repartidas entre entrenamiento y prueba,

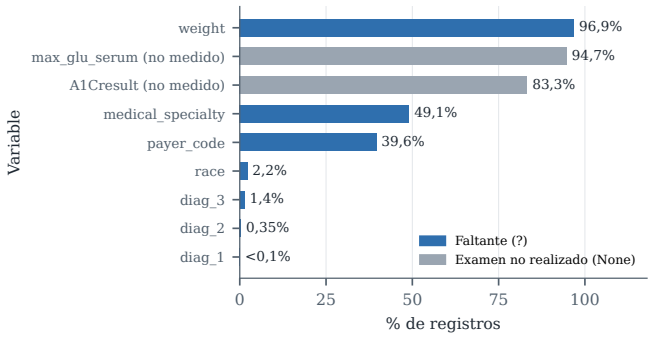


Figura 1. Porcentaje de registros con valor faltante («?», en azul) y de exámenes no realizados (`None`, en gris) sobre los 101 766 registros originales.

Cuadro II
CODIFICACIÓN DE LAS VARIABLES

Variables	**Codificación**
Conteos de la hospitalización, n.º de diagnósticos y variables creadas	Estandarización ($\mu = 0$, $\sigma = 1$)
Visitas ambulatorias, urgencias y hospitalizaciones previas	$\log(1 + x)$ y estandarización (asimetría de hasta 21,2; 87–93 % de ceros)
Edad	Ordinal (0–9)
Género, `change`, `diabetesMed`	Binaria (0/1)
Raza, tipo y fuente de admisión, destino al alta, especialidad, diagnósticos (grupos), glucosa, HbA1c, fármacos	*One-hot* (variables nominales; los códigos numéricos no tienen orden)

el modelo se evaluaría sobre pacientes que ya conoce y su desempeño se sobrestimaría (fuga de información). Siguiendo a [2], se conservó solo la primera hospitalización de cada paciente, identificada por el menor `encounter_id`. Este orden es cronológico: el número de hospitalizaciones en el año previo crece con la posición de la fila dentro de cada paciente (correlación de Spearman de 0,74). La depuración siguió este orden: (i) se eliminaron 2 423 hospitalizaciones cuyo destino al alta fue fallecimiento u hospicio (códigos 11, 13, 14, 19, 20 y 21), pues esos pacientes no pueden ser readmitidos (quedan 99 343); (ii) se eliminaron 3 registros con género inválido (99 340); y (iii) se conservó la primera hospitalización por paciente, lo que deja **69 987 registros**. Esta decisión garantiza independencia entre muestras, pero reduce los datos en un 31 % y cambia la población: las primeras hospitalizaciones tienen menos historial previo y una tasa de readmisión menor (9,0 % frente a 11,2 %), por lo que los resultados describen a pacientes en su primera hospitalización y no deben extrapolarse a pacientes recurrentes.

Datos faltantes e imputación. Los faltantes vienen codificados como «?» (Fig. 1). La estrategia por variable fue: (i) `weight` (96,9 % faltante) se eliminó, pues cualquier imputación inventaría casi toda la columna; (ii) `payer_code` (39,6 %) se eliminó por su alto porcentaje de faltantes y porque sus códigos no están documentados; (iii) en `medical_specialty` (49,1 %), `race` (2,2 %) y los diagnósticos secundarios, el faltante se codificó como una categoría propia, «Desconocido», en lugar de imputar con la moda, porque la ausencia del dato probablemente no es aleatoria y puede ser informativa; (iv) los códigos administrativos sin información (*NULL*, *Not Mapped*, *Not Available*) se agruparon también como «Desconocido». Además, en `max_glu_serum` (94,7 %) y `A1Cresult` (83,3 %) el valor `None` no es un faltante sino «examen no realizado», y se conservó como categoría; para evitar que *pandas* lo convierta en `NaN`, el archivo se lee con `keep_default_na=False` y `na_values=['?']`. Como la categoría constante no usa estadísticos de los datos, no introduce fuga de información. Las variables numéricas no tienen faltantes.

Reducción de cardinalidad y codificación. Las columnas de diagnóstico tienen entre 694 y 756 códigos ICD-9 distintos; se agruparon en nueve categorías clínicas (circulatorio, respiratorio, digestivo, diabetes, lesiones, musculoesquelético, genitourinario, neoplasias y otras), siguiendo [2]. Las especialidades médicas se redujeron a las 10 más frecuentes más «Otra» y «Desconocido». Se eliminaron `examide` y `citoglipton` (constantes) y otros nueve fármacos usados por menos del 0,1 % de los pacientes; para no perder información se crearon dos variables: número de fármacos para diabetes en uso y número de cambios de dosis. Las listas de especialidades y fármacos dependen solo de frecuencias, no de la etiqueta, y se calcularán dentro del *pipeline* con los datos de entrenamiento de cada partición, igual que el escalado. La Tabla II resume la codificación; con todo el conjunto, tras el *one-hot* el espacio queda con 130 variables.

Análisis exploratorio. Las variables de historial y de destino al alta muestran la asociación más clara con la readmisión temprana (Fig. 2): la tasa pasa de 8,1 % en pacientes sin hospitalizaciones previas a 26,5 % en quienes tuvieron tres o más, y es de 15,2 % en los trasladados a otra institución frente a 6,9 % en los enviados a casa. También aumenta con la edad (2,0 % en menores de 10 años y entre 9 y 11 % en mayores de 60) y con la estancia (mediana de 4 frente a 3 días). La prueba de Mann–Whitney indica diferencias significativas entre clases en siete de las ocho variables numéricas, pero con efectos pequeños (diferencia de medias estandarizada de 0,35 como máximo, en las hospitalizaciones previas); con cerca de 70 000 muestras la significancia estadística no implica capacidad predictiva. La correlación de Spearman entre predictoras numéricas es baja o moderada (máxima 0,46).

I-C. Paradigma de aprendizaje

El problema se aborda como **aprendizaje supervisado de clasificación binaria**. Sea $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$ con $n = 69\,987$, $\mathbf{x}_i \in \mathbb{R}^d$ el vector de características codificado de un paciente distinto ($d = 130$ con todo el conjunto) y

$$y_i = \begin{cases} 1, & \texttt{readmitted}_i = \texttt{<30}, \\ 0, & \texttt{readmitted}_i \in \{\texttt{>30}, \texttt{NO}\}. \end{cases} \tag{1}$$

Se busca una función $f_\theta(\mathbf{x}) \approx P(y = 1 \mid \mathbf{x})$ y una regla $\hat{y} = \mathbf{1}[f_\theta(\mathbf{x}) \geq \tau]$ cuyo umbral τ se elige con datos de validación y nunca con los de prueba. Como cada muestra

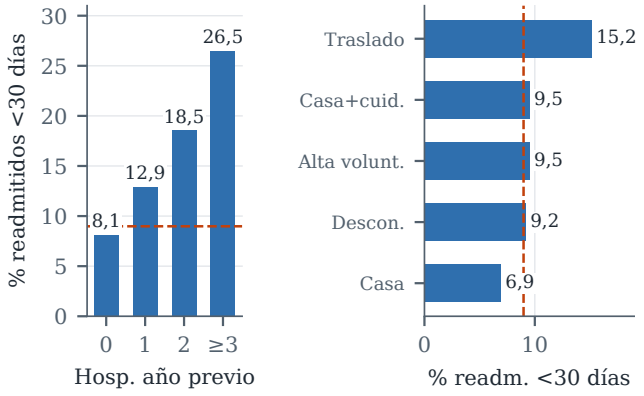


Figura 2. Tasa de readmisión en menos de 30 días según el número de hospitalizaciones en el año previo (izq.) y el destino al alta (der.). La línea discontinua marca la tasa global (8,98 %). $n = 69\,987$.

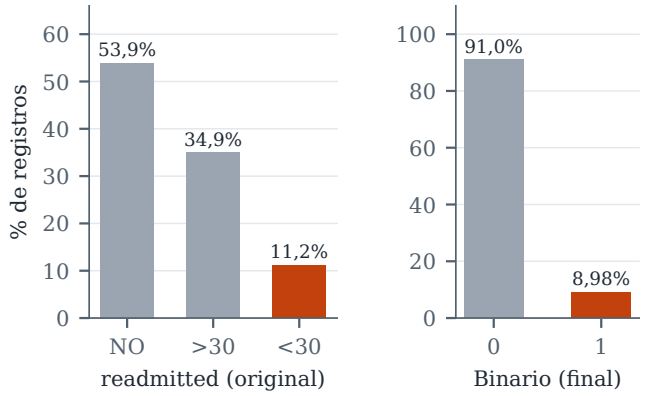


Figura 3. Distribución de la variable objetivo original con 101 766 registros (izq.) y del objetivo binario tras la depuración, con 69 987 registros (der.). En naranja, la clase de interés (readmisión en menos de 30 días).

corresponde a un paciente distinto, las observaciones pueden tratarse como independientes y bastan particiones estratificadas. Dado el desbalance ($n_1 = 6\,285$ positivos y $n_0 = 63\,702$ negativos, aproximadamente 1:10,1; Fig. 3), el entrenamiento minimiza un riesgo ponderado por clase,

$$\theta^* = \arg\min_{\theta} \; \frac{1}{n} \sum_{i=1}^{n} w_{y_i} \, \ell\big(y_i, f_\theta(\mathbf{x}_i)\big) + \lambda \, \Omega(\theta), \qquad (2)$$

con $w_c = n/(2n_c)$, que aquí equivale a $w_1 \approx 5{,}57$ y $w_0 \approx 0{,}55$.

Se eligió esta formulación porque (i) la respuesta es un evento categórico y no una magnitud continua, y la etiqueta existe, lo que descarta la regresión y el aprendizaje no supervisado; (ii) la ventana de 30 días es la usada por los trabajos más relevantes con esta base de datos (Sección II), lo que permite comparar resultados; y (iii) desde el objetivo práctico, decidir a quién intervenir antes del alta, un paciente que regresa meses después se asemeja más a uno no readmitido, por lo que una formulación de tres clases no corresponde a una decisión distinta. El costo es un desbalance marcado: un clasificador trivial que siempre prediga «no readmitido» alcanza 91,0 % de exactitud. En consecuencia, la evaluación se basará en AUC-ROC, AUC-PR, sensibilidad, F1 y exactitud balanceada; las particiones serán estratificadas, y el balanceo (pesos de clase o sobremuestreo) se aplicará solo dentro de los *folds* de entrenamiento.

II. Estado del arte

Se revisaron cuatro artículos de revista que usan la misma base de datos; la Tabla III los resume.

Strack *et al.* (2014) [2], en *BioMed Research International*, crearon la base de datos para estudiar si medir la HbA1c se asocia con la readmisión. Con 69 984 pacientes (primera hospitalización, excluyendo fallecidos y hospicio) ajustaron un modelo de regresión logística multivariable (paradigma supervisado, objetivo binario <30 días), evaluado mediante pruebas de significancia estadística y razones de *odds* ($\mathrm{OR} = e^{\beta_j}$, el cambio multiplicativo en las *odds* de readmisión por cada unidad de la variable j). Concluyeron que medir la HbA1c se asocia con menor readmisión y que esa relación depende del diagnóstico primario. No reportan métricas predictivas.

Cuadro III
Resumen de trabajos con la base *Diabetes 130-US Hospitals*

Trabajo	Técnicas	Validación	Mejor resultado
Strack 2014 [2]	Regresión logística	Pruebas de significancia; OR	No predictivo
Shang 2021 [5]	RF, Naive Bayes, ensamble de árboles	80/20; submuestreo y SMOTE	RF, AUC ≈0,66
Liu 2024 [6]	11 modelos (RF, XGB, SVM, *k*-NN, MLP, LSTM…)	*Group* 5-*fold*; SMOTE; GWO	RF, AUROC 0,63 (XGB 0,64)
Salim 2026 [7]	LR, RF, XGB, LightGBM, *stacking*	CV anidada 5×3; costo; Platt	XGB, AUC 0,664 (0,688 cal.)

Shang *et al.* (2021) [5], en *BMC Medical Informatics and Decision Making*, compararon *Random Forest* (RF), *Naive Bayes* y un ensamble de árboles de decisión para la readmisión a 30 días (clasificación binaria). Eliminaron variables con muchos faltantes, imputaron la raza con la moda, agruparon los diagnósticos en 16 tipos y seleccionaron 23 variables. Validaron con partición 80/20 y probaron submuestreo y SMOTE para el desbalance; la métrica fue el AUC. RF fue el mejor modelo, con un AUC de aproximadamente 0,66 según lo reportado en [7].

Liu *et al.* (2024) [6], en *Journal of Medical Artificial Intelligence*, compararon 11 algoritmos: RF, XGBoost, árbol de decisión, SVM lineal y RBF, regresión logística, *k*-NN, *Naive Bayes*, AdaBoost, perceptrón multicapa y LSTM. Usaron *one-hot*, estandarización y selección de variables con *Grey Wolf Optimizer* (de 55 a 43 variables). Validaron con *group k-fold* ($k = 5$) por paciente, aplicando SMOTE solo en entrenamiento, y reportaron F1, exactitud, precisión, sensibilidad y AUROC. RF fue el mejor según F1 (0,83) y exactitud (0,88), con un AUROC de 0,63 (XGBoost: 0,64). Estas métricas ponderadas están dominadas por la clase mayoritaria: con 11 % de positivos, el clasificador trivial ya alcanza cerca de 0,89 de exactitud.

Salim e Ibrahim (2026) [7], en *Healthcare*, evaluaron regresión logística, RF, XGBoost, LightGBM y un *stacking*, con validación cruzada anidada estratificada (5 *folds* externos y 3 internos), aprendizaje sensible al costo y calibración de Platt. Usaron los 101 766 registros, sin depurar pacientes repetidos. Midieron AUC, AUC-PR, F1 y el puntaje de Brier, $\mathrm{BS} = \frac{1}{N}\sum_{i=1}^{N}(\hat{p}_i - y_i)^2$, que evalúa la calibración de las probabilidades predichas (menor es mejor). XGBoost obtuvo un AUC de 0,664 en validación anidada (0,688 calibrado), AUC-PR de 0,215, F1 de 0,27 y Brier de 0,094; la regresión logística llegó a 0,657.

Síntesis. Todos los trabajos plantean un problema supervisado binario y coinciden en que el desempeño alcanzable con esta base es modesto: un AUC entre 0,63 y 0,69, aun con modelos complejos. Esto se explica porque los datos son administrativos y no incluyen factores determinantes como la adherencia al tratamiento o el apoyo social. Los trabajos también muestran dos riesgos metodológicos que este proyecto evitará: no tratar los pacientes repetidos, lo que genera fuga de información, y reportar métricas dominadas por la clase mayoritaria. Por ello, este proyecto usará una hospitalización por paciente, métricas adecuadas al desbalance e intervalos de confianza, y tomará un AUC cercano a 0,65–0,69 como referencia de comparación.

Referencias

[1] S. F. Jencks, M. V. Williams y E. A. Coleman, "Rehospitalizations among patients in the Medicare fee-for-service program," *N. Engl. J. Med.*, vol. 360, no. 14, pp. 1418–1428, 2009.

[2] B. Strack, J. P. DeShazo, C. Gennings, J. L. Olmo, S. Ventura, K. J. Cios y J. N. Clore, "Impact of HbA1c measurement on hospital readmission rates: Analysis of 70,000 clinical database patient records," *BioMed Res. Int.*, vol. 2014, art. 781670, 2014, doi: 10.1155/2014/781670. [En línea]. [Url]: https://onlinelibrary.wiley.com/doi/10.1155/2014/781670

[3] J. Clore, K. Cios, J. DeShazo y B. Strack, "Diabetes 130-US Hospitals for Years 1999–2008," UCI Machine Learning Repository, 2014, doi: 10.24432/C5230J.

[4] R. Ihab, "Diabetes Hospital Readmission Dataset," Kaggle, 2026.

[5] Y. Shang, K. Jiang, L. Wang, Z. Zhang, S. Zhou, Y. Liu, J. Dong y H. Wu, "The 30-days hospital readmission risk in diabetic patients: predictive modeling with machine learning classifiers," *BMC Med. Inform. Decis. Mak.*, vol. 21, supl. 2, art. 57, 2021, doi: 10.1186/s12911-021-01423-y. [Url]: https://link.springer.com/article/10.1186/s12911-021-01423-y

[6] V. B. Liu, L. Y. Sue y Y. Wu, "Comparison of machine learning models for predicting 30-day readmission rates for patients with diabetes," *J. Med. Artif. Intell.*, vol. 7, art. 23, 2024, doi: 10.21037/jmai-24-70. [Url]: https://jmai.amegroups.org/article/view/9179/html

[7] S. S. Salim y A. A. Ibrahim, "A machine learning approach for predicting 30-day hospital readmission in patients with diabetes," *Healthcare*, vol. 14, no. 9, art. 1185, 2026, doi: 10.3390/healthcare14091185. [Url]: https://www.mdpi.com/2227-9032/14/9/1185